

# Lecture 13 - Markov chain Monte Carlo

赵尉辰

南开大学 统计与数据科学学院

# 目录

- 1 背景：Monte Carlo 方法与采样问题
- 2 Markov Chain Monte Carlo
  - Gibbs Sampling
  - Metropolis-Hastings 算法
- 3 模拟退火

# 目录

## 1 背景：Monte Carlo 方法与采样问题

## 2 Markov Chain Monte Carlo

- Gibbs Sampling
- Metropolis-Hastings 算法

## 3 模拟退火

# 近似计算积分


考虑一个积分计算的问题, 对于  $f: S \rightarrow \mathbb{R}$ , 定义

$$I = \int_S f(x) dx.$$

# 近似计算积分

若  $S = [0, 1]$ , 则可以近似计算  $I$ :

$$\hat{I}_n = \frac{1}{n} \sum_{i=0}^{n-1} f\left(\frac{i+1/2}{n}\right).$$



如果  $\sup_{x \in [0,1]} |f'(x)| < M < \infty$ , 则近似误差为  $\mathcal{O}(n^{-1})$ .

# 近似计算积分

进一步，若  $S = [0, 1] \times [0, 1]$ ，则可以近似计算  $I$ ：

$$\hat{I}_n = \frac{1}{m^2} \sum_{i=0}^{m-1} \sum_{j=0}^{m-1} f\left(\frac{i+1/2}{m}, \frac{j+1/2}{m}\right)$$

此时， $n = m^2$ ，近似误差为  $\mathcal{O}(n^{-1/2})$ 。更一般地，对于  $S = [0, 1]^d$ ，近似误差为  $\mathcal{O}(n^{-1/d})$ 。

这说明随着维度的增长，近似计算积分越来越困难，这经常被称为“**维度诅咒** (curse of dimensionality)”。

然而在统计物理、机器学习等领域中，这样高维积分计算问题非常普遍。

# 贝叶斯推断

## 推断任务

在机器学习中，所有未知的量，无论是对未来的预测，系统的隐藏状态，还是模型的参数，都被视为随机变量，并被赋予概率分布。**推断任务**是指根据已知数据，计算这些随机变量的后验分布。

设 $\phi$ 是未知变量， $\mathcal{D}$ 是已知变量，给定先验 $p(\phi)$ 和似然 $p(\mathcal{D}|\phi)$ ，我们可以通过贝叶斯定理计算后验：

$$p(\phi|\mathcal{D}) = \frac{p(\phi)p(\mathcal{D}|\phi)}{p(\mathcal{D})}$$

计算的瓶颈在于归一化系数

$$p(\mathcal{D}) = \int p(\mathcal{D}|\phi)p(\phi)d\phi$$

尤其是在高维情形。

# Monte Carlo 方法

对于  $f : S \rightarrow \mathbb{R}$ , 积分可以改写为

$$I = \int_S f(x) dx = \int_S \varphi(x) \pi(x) dx = \mathbb{E}_\pi[\varphi].$$

其中  $\pi$  是  $S$  上的概率分布,  $\varphi : x \mapsto f(x)/\pi(x)$ .

## Monte Carlo 方法

- 得到  $n$  个独立的服从  $\pi$  的样本  $X_1, X_2, \dots, X_n$
- 计算

$$\hat{I}_n = \frac{1}{n} \sum_{i=1}^n \varphi(X_i)$$



# Monte Carlo 方法的近似误差

$$\begin{aligned}(I - \hat{I}_n)^2 &= I^2 - 2I\hat{I}_n + \hat{I}_n^2 \\ &= I^2 - \frac{2I}{n} \sum_{i=1}^n \varphi(X_i) + \frac{1}{n^2} \sum_{i=1}^n \varphi(X_i)^2 + \frac{1}{n^2} \sum_{i \neq j} \varphi(X_i) \varphi(X_j).\end{aligned}$$

由于  $X_i$  i.i.d. 且  $I = \mathbb{E}_\pi[\varphi(X)]$ , 那么

$$\begin{aligned}\mathbb{E}_\pi[(I - \hat{I}_n)^2] &= I^2 - 2I^2 + \frac{1}{n} \mathbb{E}_\pi[\varphi(X_1)^2] + \frac{1}{n^2} n(n-1) I^2 \\ &= \frac{\mathbb{E}_\pi[\varphi(X_1)^2] - I^2}{n} = \frac{\mathbb{V}_\pi(\varphi(X_1))}{n}\end{aligned}$$

于是如果 test function 满足  $|\varphi(x)| \leq 1, \forall x$ , 那么

$$\sqrt{\mathbb{E}_\pi[(I - \hat{I}_n)^2]} = \frac{\sqrt{\text{Var}_\pi(\varphi(X_1))}}{\sqrt{n}} \leq \frac{1}{\sqrt{n}}$$

这说明 Monte Carlo 方法的近似误差是**维度无关**的!

# 集中不等式<sup>123</sup>



## Michel Talagrand awarded the 2024 Abel Prize

«for his groundbreaking contributions to probability theory and functional analysis, with outstanding applications in mathematical physics and statistics.»

<sup>1</sup>Wainwright M J. High-dimensional statistics: A non-asymptotic viewpoint[M]. Cambridge university press, 2019.

<sup>2</sup>Dubhashi D P, Panconesi A. Concentration of measure for the analysis of randomized algorithms[M]. Cambridge University Press, 2009.

<sup>3</sup>Boucheron, Stéphane, Gábor Lugosi, and Pascal Massart, Concentration Inequalities: A Nonasymptotic Theory of Independence, Oxford Academic, 2013.

# 机器学习

## 监督学习的目标

学习一个映射函数  $f: \mathcal{X} \rightarrow \mathcal{Y}$ ，使得预测结果尽可能准确。

- 损失函数  $\ell(f(x), y)$  衡量预测值与真实值的差异
- 常用损失函数：平方损失、交叉熵、0-1损失等

# 机器学习

机器学习主流是概率模型<sup>45</sup>，一般认为数据是随机变量，服从一定的概率分布。

## 定义 1 (期望风险)

期望风险 (*Expected Risk*) 定义为

$$R_{\text{exp}}(f) = \mathbb{E}_{(x,y) \sim p(x,y)} [\ell(f(x), y)]$$

- 反映模型在 **全体数据分布** 上的表现
- 理论上的理想优化目标
- 关键问题：真实数据分布  $p(x, y)$  未知！

<sup>4</sup>Murphy K P. Probabilistic machine learning: an introduction[M]. MIT press, 2022.

<sup>5</sup>Murphy K P. Probabilistic machine learning: Advanced topics[M]. MIT press, 2023.

# 经验风险

## 定义 2 (经验风险)

经验风险 (*Empirical Risk*) 定义为

$$R_{\text{emp}}(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i)$$

- 基于 训练数据集  $\{(x_i, y_i)\}_{i=1}^n$  的近似
- 实际优化目标

# Monte Carlo 方法<sup>6</sup>

Monte Carlo 方法近似  $\mathbb{E}_\pi[\varphi(X)] \Leftrightarrow$  simulation method to sample  $\pi$

---

<sup>6</sup>Liu Jun. Monte Carlo strategies in scientific computing[M]. New York: springer, 2001.

# 采样

## 问题 1 (采样)

设  $\pi$  是一个概率分布, **采样问题(Sampling)**是指: 如何获得随机样本 $x$ , 使得 $x$ 的分布为 $\pi$ 。

## 问题 2 (采样)

给定光滑函数 $V: \mathbb{R}^d \rightarrow \mathbb{R}$ , 如何获得 $\mathbb{R}^d$ 上的随机样本服从概率分布

$$\pi = \frac{1}{Z} e^{-V}, \quad \pi \propto e^{-V}$$

我们一般称 $V$ 为位势函数(*potential function*)

# 采样

## 问题 1 (采样)

设  $\pi$  是一个概率分布, **采样问题(Sampling)**是指: 如何获得随机样本 $x$ , 使得 $x$ 的分布为 $\pi$ 。

## 问题 2 (采样)

给定光滑函数 $V: \mathbb{R}^d \rightarrow \mathbb{R}$ , 如何获得 $\mathbb{R}^d$ 上的随机样本服从概率分布

$$\pi = \frac{1}{Z} e^{-V}, \quad \pi \propto e^{-V}$$

我们一般称 $V$ 为位势函数(*potential function*)



# 生成

## 生成任务

在机器学习中，**生成任务** 是指模型的目标为生成新的数据实例，这些实例与已有数据(训练数据)具有相似的特征或模式，常见的生成任务包括文本生成、图像生成、视频生成等。

处理生成任务通常包含两个部分：


### (1) 学习数据分布

学习通常利用深度神经网络实现，神经网络是一个参数化的模型，需要通过数学优化更新模型参数。

### (2) 根据数据分布生成实例

生成新的数据样本即就是从数据分布中**采样**，需要通过采样算法实现。

# 随机模拟



- 随机数/基本随机变量/随机过程/随机向量的模拟
- Rejection Sampling
- Importance Sampling and Variance Reduction Methods

# 模拟高斯分布的 Galton's machine



# 目录

1 背景：Monte Carlo 方法与采样问题

2 Markov Chain Monte Carlo

- Gibbs Sampling
- Metropolis-Hastings 算法

3 模拟退火

# Markov Chain Monte Carlo (MCMC)

## 定义 3 (Markov链)

一个 **Markov链** 是一个随机过程  $\{X_n\}_{n=0}^{\infty}$ , 满足: 未来状态只依赖于当前状态, 而与过去状态无关。即, 对于任意的  $n$  和状态  $i, j$ , 有:

$$P(X_{n+1} = j \mid X_n = i, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) = P(X_{n+1} = j \mid X_n = i)$$

进一步, 如果转移概率不随时间变化, 即:

$$P(X_{n+1} = j \mid X_n = i) = P(X_1 = j \mid X_0 = i) \quad \forall n$$

那么我们称 **Markov链** 是**时齐的**。

# Markov Chain Monte Carlo (MCMC)

## 定义 4 (不变分布)

设  $\{X_n\}_{n=0}^{\infty}$  是一个 Markov 链，其状态空间为  $S$ 。如果存在一个概率分布  $\pi$  满足以下条件：

$$\pi(j) = \sum_{i \in S} \pi(i) P_{ij} \quad \forall j \in S$$

其中  $P_{ij}$  是从状态  $i$  转移到状态  $j$  的概率，则称  $\pi$  为该 Markov 链的不变分布 (Invariant Distribution)。

# Markov Chain Monte Carlo (MCMC)

MCMC的思想即是：构造一个Markov链，使得它的平稳分布是我们采样的目标分布  $\pi$ 。那么从任意状态分布(容易获得样本的分布)出发，经过充分的状态转移，就能获得目标分布 $\pi$ 的样本。

给定目标分布 $\pi$ ，构造Markov链 $X_n$ ，使得， $n \rightarrow \infty$ ， $X_n \sim \pi$ ，那么随着 $N \rightarrow \infty$

$$\frac{1}{N} \sum_{n=1}^N \varphi(X_n) \rightarrow \int \varphi(x) \pi(x) dx$$

# Gibbs Sampling

设目标分布为

$$\pi(x) = \pi(x_1, x_2, \dots, x_d).$$

记  $x_{-i} := (x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_d)$ .

## Systematic scan Gibbs sampler

- ❶ 选择初始状态  $X^{(0)} = (X_1^{(0)}, \dots, X_d^{(0)})$ 。
- ❷ 对于每一步  $t = 1, 2, \dots, N$ :
  - 从提议分布  $\pi_{X_1|X_{-1}}(\cdot | X_2^{(t-1)}, \dots, X_d^{(t-1)})$  中生成候选状态  $X_1^{(t)}$ 。
  - ...
  - 采样  $X_j^{(t)} \sim \pi_{X_j|X_{-j}}(\cdot | X_1^{(t)}, \dots, X_{j-1}^{(t)}, X_{j+1}^{(t-1)}, \dots, X_d^{(t-1)})$
  - ...
  - 采样  $X_d^{(t)} \sim \pi_{X_d|X_{-d}}(\cdot | X_1^{(t)}, \dots, X_{d-1}^{(t)})$



# Gibbs Sampling

## Random scan Gibbs sampler

- ❶ 选择初始状态  $X^{(0)} = (X_1^{(0)}, \dots, X_d^{(0)})$ 。
- ❷ 对于每一步  $t = 1, 2, \dots, N$ :
  - 从维度指标集中  $\{1, 2, \dots, d\}$  采样指标  $J$ ，一般可以均匀的采样；
  - 采样  $X_J^{(t)} \sim \pi_{X_J|X_{-J}} \left( \cdot | X_1^{(t-1)}, \dots, X_{J-1}^{(t-1)}, X_{J+1}^{(t-1)}, \dots, X_d^{(t-1)} \right)$

# Gibbs Sampling

- 联合分布  $\pi$  是否能由条件分布  $\pi_{X_i|X_{-i}}$  唯一确定？
- Gibbs Sampler 是否以目标分布  $\pi$  为不变分布？
- Gibbs Sampler 是否能收敛到不变分布  $\pi$  ？

# Gibbs Sampling

## 定理 1 (Hammersley-Clifford)

设概率密度  $\pi(x_1, x_2, \dots, x_d)$  满足正定性条件 (*positivity condition*), 即如果对于所有  $x_1, \dots, x_d$ , 边缘密度  $\pi_{X_i}(x_i) > 0$ , 就有

$$\pi(x_1, x_2, \dots, x_d) > 0$$

成立, 那么对于所有  $(z_1, \dots, z_d) \in \text{supp}(\pi)$ , 即  $\pi(z_1, \dots, z_d) > 0$ ,

$$\pi(x_1, x_2, \dots, x_d) \propto \prod_{j=1}^d \frac{\pi_{X_j|X_{-j}}(x_j|x_1, \dots, x_{j-1}, z_{j+1}, \dots, z_d)}{\pi_{X_j|X_{-j}}(z_j|x_1, \dots, x_{j-1}, z_{j+1}, \dots, z_d)}$$

证明...

# Gibbs Sampling

记  $x^{(t)} := (x_1^{(t)}, \dots, x_d^{(t)})$ , systematic scan Gibbs sampler 的转移概率为

$$\begin{aligned} P\left(x^{(t-1)}, x^{(t)}\right) &= \pi_{X_1|X_{-1}}\left(x_1^{(t)} \mid x_2^{(t-1)}, \dots, x_d^{(t-1)}\right) \times \\ &\quad \pi_{X_2|X_{-2}}\left(x_2^{(t)} \mid x_1^{(t)}, x_3^{(t-1)}, \dots, x_d^{(t-1)}\right) \times \cdots \\ &\quad \times \pi_{X_d|X_{-d}}\left(x_d^{(t)} \mid x_1^{(t)}, \dots, x_{d-1}^{(t)}\right). \end{aligned}$$

random scan Gibbs sampler 的转移概率为

$$P\left(x^{(t-1)}, x^{(t)}\right) = \frac{1}{d} \sum_{j=1}^d \pi_{X_j|X_{-j}}\left(x_j^{(t)} \mid x_{-j}^{(t-1)}\right) \delta_{x_{-j}^{(t-1)}}\left(x_{-j}^{(t)}\right)$$

其中  $\delta_{x_{-j}^{(t-1)}}$  为  $x_{-j}^{(t-1)}$  的 Dirac 测度。

# Gibbs Sampling

## 命题 1

*Systematic scan Gibbs sampler* 的不变分布为  $\pi$ .

证明...

## Remark 1

*Systematic scan Gibbs sampler* 是不可逆的。

# Gibbs Sampling

## 命题 2

*Random scan Gibbs sampler* 的不变分布为  $\pi$ .

## Remark 2

*Random scan Gibbs sampler* 是**可逆**的。

# Gibbs sampler for Ising model

设

$$\pi = \frac{1}{Z} e^{-\beta H(\sigma)},$$

其中  $H(\sigma) = -J \sum_{(ij) \in B} \sigma(i)\sigma(j) - h \sum_i \sigma(i)$ . 考虑转移核

$$P(\sigma, \sigma^i) = \frac{1}{N} \cdot \frac{e^{-\beta H(\sigma^i)}}{e^{-\beta H(\sigma)} + e^{-\beta H(\sigma^i)}}$$

其中  $\frac{e^{-\beta H(\sigma^i)}}{e^{-\beta H(\sigma)} + e^{-\beta H(\sigma^i)}}$  即为

$$\pi_{\sigma'_i | \sigma_{-i}} = \frac{\pi(\sigma'_i, \sigma_{-i})}{\pi(\sigma_{-i})} = \frac{\pi(\sigma^i)}{\int_{\sigma_i = \{\pm 1\}} \pi(\sigma)}$$

# Gibbs Sampling

## 定义 5 ( $\pi$ -不可约)

Markov链被称为 $\pi$ -不可约的，如果对于任何满足

$$\pi(A) \triangleq \int_A \pi(x_1, \dots, x_d) dx_1 \dots dx_d > 0$$

的集合 $A$ ，从任意初始状态 $x$ 出发，存在某个正整数 $t$ ，使得链在 $t$ 步后到达 $A$ 的概率为正。

这一条件确保了链在 $\pi$ 的支撑上是“**连通的**”，即无法将状态空间分解为两个或多个  $\pi$  正测度的不相交子集，使得链无法从一个子集到达另一个。



# Gibbs Sampling

## 命题 3

假设  $\pi$  满足正定性条件, 那么 *Gibbs sampler*  $X^{(t)}$  是一个  $\pi$ -不可约、正常返的 *Markov* 链。

## 定理 2

假设  $\pi$  满足正定性条件, 那么对于任意可积函数  $\varphi: S \rightarrow \mathbb{R}$

$$\lim_{t \rightarrow \infty} \frac{1}{t} \sum_{i=1}^t \varphi(X^{(i)}) = \int_S \varphi(x) \pi(x) dx$$

# Metropolis-Hastings 算法

设目标分布为 $\pi$ .

## Metropolis-Hastings

- 1 选择初始状态  $x^{(0)}$ .
- 2 对于每一步  $t = 1, 2, \dots, N$ :
  - 从提议分布  $q(x^*|x^{(t-1)})$  中生成候选状态  $x^*$ .
  - 计算接受概率:

$$\alpha(x^*|x^{(t-1)}) = \min \left( 1, \frac{\pi(x^*)q(x^{(t-1)}|x^*)}{\pi(x^{(t-1)})q(x^*|x^{(t-1)})} \right)$$

- 以概率  $\alpha$  接受候选状态  $x^*$ , 否则保持状态  $x^{(t-1)}$ .

具体操作为: 采样  $U \sim \text{Uniform}[0, 1]$ , 若  $\alpha \leq U$ , 则接受新状态, 否则保持不变。

# Metropolis-Hastings 算法

- Metropolis-Hastings 算法可以处理非归一化的概率密度，即，对于任意  $\tilde{\pi}(x) \propto \pi(x)$ ，有

$$\frac{\pi(x^*) q(x^{(t-1)} | x^*)}{\pi(x^{(t-1)}) q(x^* | x^{(t-1)})} = \frac{\tilde{\pi}(x^*) q(x^{(t-1)} | x^*)}{\tilde{\pi}(x^{(t-1)}) q(x^* | x^{(t-1)})}.$$

# Metropolis-Hastings 算法

## 命题 4

MH 算法的转移概率为

$$P\left(x^{(t-1)}, x^{(t)}\right) = \alpha\left(x^{(t)} \mid x^{(t-1)}\right) q\left(x^{(t)} \mid x^{(t-1)}\right) + \left(1 - \alpha\left(x^{(t-1)}\right)\right) \delta_{x^{(t-1)}}\left(x^{(t)}\right)$$

其中  $\delta_{x^{(t-1)}}$  是在  $x^{(t-1)}$  处的 Dirac 测度,

$$\alpha\left(x^{(t-1)}\right) \triangleq \int_S \alpha\left(x \mid x^{(t-1)}\right) q\left(x \mid x^{(t-1)}\right) dx$$

表示在给定当前状态  $x^{(t-1)}$  时, 会接受并更新状态的概率。

证明...

# Metropolis-Hastings 算法

## 命题 5

$MH$ 算法是关于 $\pi$ 可逆的, 即

$$\pi\left(x^{(t-1)}\right) P\left(x^{(t-1)}, x^{(t)}\right)=\pi\left(x^{(t)}\right) P\left(x^{(t)}, x^{(t-1)}\right)$$

因此 $\pi$ 也是 $MH$ 算法的不变分布。

证明...

# Metropolis-Hastings 算法的不可约性<sup>7</sup>

## 命题 6 (Informal)

如果存在  $\delta, \epsilon > 0$ , 使得对任意  $x \in S$ , 有

$$|x - x'| < \delta \Rightarrow q(x|x') \geq \epsilon,$$

那么MH算法是 $\pi$ -不可约的。

一个更强的条件是: 如果对任意  $x, x^* \in \text{supp}(\pi)$ , 有  $q(x^*|x) > 0$ , 那么MH链 $\pi$ -不可约。

---

<sup>7</sup>Gareth O. Roberts. Jeffrey S. Rosenthal. "General state space Markov chains and MCMC algorithms." Probab. Surveys 1 20 - 71, 2004. <https://doi.org/10.1214/1549578041000000024>

# Metropolis-Hastings 算法

## 定理 3

假设 MH 链是  $\pi$ -不可约的, 那么对于任意可积函数  $\varphi: S \rightarrow \mathbb{R}$

$$\lim_{t \rightarrow \infty} \frac{1}{t} \sum_{i=1}^t \varphi(X^{(i)}) = \int_S \varphi(x) \pi(x) dx$$

# Proposal 的选择

## Symmetric Proposals

考虑 proposal 分布为

$$q\left(x|x^{(t-1)}\right)=q\left(x^{(t-1)}|x\right)$$

那么Metropolis-Hastings接受率为

$$\frac{\pi(x) q\left(x^{(t-1)}|x\right)}{\pi\left(x^{(t-1)}\right) q\left(x|x^{(t-1)}\right)}=\frac{\pi(x)}{\pi\left(x^{(t-1)}\right)}.$$

一种具体的实现: Random Walk Proposals

$$X=X^{(t-1)}+W$$

其中 $W$ 服从 $d$ 为标准高斯分布,  $W \sim \mathcal{N}(0, I_d)$ 。



# Proposal 的选择

## Independent Proposals

考虑 proposal 分布为

$$q\left(x|x^{(t-1)}\right)=q(x)$$

那么Metropolis-Hastings接受率为

$$\frac{\pi(x) q\left(x^{(t-1)}|x\right)}{\pi\left(x^{(t-1)}\right) q\left(x|x^{(t-1)}\right)}=\frac{\pi(x)}{q(x)} \frac{q\left(x^{(t-1)}\right)}{\pi\left(x^{(t-1)}\right)}.$$

# Proposal 的选择

## 定义 6 (Langevin扩散(Langevin Diffusion))

设  $V : \mathbb{R}^d \rightarrow \mathbb{R}$  是一个位势, 我们称随机微分方程(*Stochastic Differential Equations, SDEs*)

$$dX_t = -\nabla V(X_t)dt + \sqrt{2}dB_t.$$

的解为  $V$  对应的 *Langevin扩散* / *Langevin Dynamics*, 其中  $B_t$  为一个标准布朗运动。  
*Langevin* 扩散的不变测度为

$$\pi \propto e^{-V}$$

## Langevin Proposals

$$X = X^{(t-1)} - \sigma \nabla \log \pi|_{X^{(t-1)}} + 2\sigma W$$

其中  $W \sim \mathcal{N}(0, I_d)$ ,  $\nabla \log \pi|_{X^{(t-1)}}$  表示在  $X^{(t-1)}$  处的目标密度函数的对数梯度,  $\sigma$  为可调整超参数。

# Proposal 的选择

## 定义 6 (Langevin扩散(Langevin Diffusion))

设  $V : \mathbb{R}^d \rightarrow \mathbb{R}$  是一个位势, 我们称随机微分方程(Stochastic Differential Equations, SDEs)

$$dX_t = -\nabla V(X_t)dt + \sqrt{2}dB_t.$$

的解为  $V$  对应的 **Langevin扩散**/Langevin Dynamics, 其中  $B_t$  为一个标准布朗运动。  
Langevin扩散的不变测度为

$$\pi \propto e^{-V}$$

## Langevin Proposals

$$X = X^{(t-1)} - \sigma \nabla \log \pi|_{X^{(t-1)}} + 2\sigma W$$

其中  $W \sim \mathcal{N}(0, I_d)$ ,  $\nabla \log \pi|_{X^{(t-1)}}$  表示在  $X^{(t-1)}$  处的目标密度函数的对数梯度,  $\sigma$  为可调整超参数。

# Proposal 的选择

## Informed Proposals

- 2020 JASA - Informed Proposals for Local MCMC in Discrete Spaces
- 2021 ICML - Oops i took a gradient: Scalable sampling for discrete distributions
- 2022 ICLR - Path auxiliary proposal for MCMC in discrete space
- 2022 ICML - A Langevin-like Sampler for Discrete Distributions
- 2022 NIPS - Optimal scaling for locally balanced proposals in discrete spaces
- 2023 ICLR - Any-scale balanced samplers for discrete space
- 2024 NIPS - Gradient-based Discrete Sampling with Automatic Cyclical Scheduling

# 总结

- Monte Carlo 方法: 计算

$$I = \int_S f(x) dx = \int_S \varphi(x) \pi(x) dx = \mathbb{E}_\pi[\varphi].$$

转化为 simulation method to sample  $\pi$

- 采样问题: 设  $\pi$  是一个概率分布, 如何获得随机样本  $x$ , 使得  $x$  的分布为  $\pi$ 。
- Markov chain Monte Carlo

# 总结: Gibbs sampler

## • Systematic scan Gibbs sampler

- ① 选择初始状态  $X^{(0)} = (X_1^{(0)}, \dots, X_d^{(0)})$ 。
- ② 对于每一步  $t = 1, 2, \dots, N$ :
  - 从提议分布  $\pi_{X_1|X_{-1}}(\cdot | X_2^{(t-1)}, \dots, X_d^{(t-1)})$  中生成候选状态  $X_1^{(t)}$ 。
  - ...
  - 采样  $X_j^{(t)} \sim \pi_{X_j|X_{-j}}(\cdot | X_1^{(t)}, \dots, X_{j-1}^{(t)}, X_{j+1}^{(t-1)}, \dots, X_d^{(t-1)})$
  - ...
  - 采样  $X_d^{(t)} \sim \pi_{X_d|X_{-d}}(\cdot | X_1^{(t)}, \dots, X_{d-1}^{(t)})$

## • Random scan Gibbs sampler

- ① 选择初始状态  $X^{(0)} = (X_1^{(0)}, \dots, X_d^{(0)})$ 。
- ② 对于每一步  $t = 1, 2, \dots, N$ :
  - 从维度指标集中  $\{1, 2, \dots, d\}$  采样指标  $J$ ，一般可以均匀的采样；
  - 采样  $X_J^{(t)} \sim \pi_{X_J|X_{-J}}(\cdot | X_1^{(t-1)}, \dots, X_{J-1}^{(t-1)}, X_{J+1}^{(t-1)}, \dots, X_d^{(t-1)})$

# 总结: Gibbs sampler

## 命题 7

*Systematic/Random scan Gibbs sampler* 的不变分布为  $\pi$ , 且在  $\pi$  满足正定性条件下, 对于任意可积函数  $\varphi : S \rightarrow \mathbb{R}$

$$\lim_{t \rightarrow \infty} \frac{1}{t} \sum_{i=1}^t \varphi(X^{(i)}) = \int_S \varphi(x) \pi(x) dx$$

# 总结: Metropolis-Hastings 算法

- ① 选择初始状态  $x^{(0)}$ 。
- ② 对于每一步  $t = 1, 2, \dots, N$ :
  - 从提议分布  $q(x^*|x^{(t-1)})$  中生成候选状态  $x^*$ 。
  - 计算接受概率:

$$\alpha(x^*|x^{(t-1)}) = \min \left( 1, \frac{\pi(x^*)q(x^{(t-1)}|x^*)}{\pi(x^{(t-1)})q(x^*|x^{(t-1)})} \right)$$

- 以概率  $\alpha$  接受候选状态  $x^*$ , 否则保持状态  $x^{(t-1)}$ 。

具体操作为: 采样  $U \sim \text{Uniform}[0, 1]$ , 若  $\alpha \leq U$ , 则接受新状态, 否则保持不变。



# 总结: Metropolis-Hastings 算法

## 命题 8

$MH$ 算法是关于 $\pi$ 可逆的, 因此 $\pi$ 也是 $MH$ 算法的不变分布, 而且若 $MH$ 链是 $\pi$ -不可约的, 那么对于任意可积函数  $\varphi : S \rightarrow \mathbb{R}$

$$\lim_{t \rightarrow \infty} \frac{1}{t} \sum_{i=1}^t \varphi(X^{(i)}) = \int_S \varphi(x) \pi(x) dx$$

# 目录

- 1 背景：Monte Carlo 方法与采样问题
- 2 Markov Chain Monte Carlo
  - Gibbs Sampling
  - Metropolis-Hastings 算法
- 3 模拟退火